

# Predição de Tendências no Mercado Financeiro com Machine Learning

Rafael Araujo Cabral Moreira<sup>1</sup>  
Rute Willemann<sup>1</sup>  
Prof. Dr. Leandro Zerbinatti (Orientador)<sup>1</sup>

<sup>1</sup>Faculdade de Computação e Informática (FCI)  
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<rafaelaraujo.moreira, rute.willemann@mackenzista.com.br>

<leandro.zerbinatti@mackenzie.br>

2026

## Resumo

*O mercado financeiro caracteriza-se por sua elevada volatilidade, dinamicidade e pela intrínseca complexidade no processo de tomada de decisões estratégicas de investimento. Este projeto insere-se no contexto das finanças quantitativas e da ciência de dados aplicada, motivado pela imperiosa necessidade de mitigar a assimetria de informações e aprimorar a capacidade preditiva em relação ao comportamento temporal de ativos financeiros. O objetivo geral da pesquisa consiste em desenvolver e validar um modelo preditivo de Machine Learning capaz de forecastar a tendência direcional do preço de fechamento de ações de alta liquidez negociadas na Bolsa de Valores brasileira (B3). A justificativa deste estudo fundamenta-se na relevância acadêmica e prática de democratizar ferramentas de inteligência de negócios (Business Intelligence), otimizando o suporte analítico à decisão e reduzindo os riscos operacionais no mercado de capitais. A metodologia adota uma abordagem estritamente quantitativa e aplicada, alinhada à "Opção Framework" estruturada no âmbito acadêmico, fazendo uso das bibliotecas fundamentais do ecossistema Python, em especial a scikit-learn. O dataset original foi construído via extração automatizada utilizando a API oficial do Yahoo Finance, compreendendo um histórico temporal de dois anos das cotações diárias das empresas Petrobras, Vale, Itaú, Bradesco e Ambev. Os procedimentos de preparação, tratamento, engenharia de recursos e análise exploratória de dados (EDA) foram executados para garantir a consistência das estatísticas descritivas e a integridade do pipeline. Como resultados esperados, almeja-se que o classificador supervisionado indique a direção do ativo (alta ou baixa) com uma taxa de acurácia e precisão estatisticamente superiores à probabilidade aleatória, provendo um artefato computacional robusto, reproduzível e alinhado aos princípios éticos e de responsabilidade algorítmica em Inteligência Artificial.*

**Palavras-chave:** artigo científico; norma ABNT; inteligência artificial; machine learning; mercado financeiro; séries temporais.

## Abstract

*The financial market is characterized by high volatility, dynamism, and intrinsic complexity in strategic investment decision-making. Situated within the context of quantitative finance and applied data science, this project is motivated by the critical need to mitigate information asymmetry and enhance predictive capabilities regarding the temporal behavior of financial assets. The primary objective of this research is to develop and validate a Machine Learning predictive model capable of forecasting the directional trend of closing prices for high-liquidity stocks traded on the Brazilian Stock Exchange (B3). The justification for this study lies in the academic and practical relevance of democratizing Business Intelligence tools, thereby optimizing analytical decision support and reducing operational risks in the capital markets. The methodology adopts a strictly quantitative and applied approach—aligned with the structured academic "Framework Option"—utilizing fundamental libraries of the Python ecosystem, particularly scikit-learn. The original dataset was constructed through automated extraction via the official Yahoo Finance API, encompassing a two-year historical timeframe of daily quotes for Petrobras, Vale, Itaú, Bradesco, and Ambev. Procedures for data preparation, processing, feature engineering, and exploratory data analysis (EDA) were executed to ensure the consistency of descriptive statistics and pipeline integrity. As for expected results, the supervised classifier is anticipated to indicate asset direction (upward or downward) with accuracy and precision rates statistically superior to random probability, providing a robust and reproducible computational artifact aligned with the principles of ethics and algorithmic responsibility in Artificial Intelligence.*

**Keywords:** Scientific article; ABNT standards; artificial intelligence; machine learning; financial market; time series.

## 1. Introdução

A capacidade de antecipar movimentos em mercados de capitais tem sido um dos maiores desafios empíricos e teóricos da área de negócios e finanças. Com a evolução da engenharia de dados e a popularização de pipelines de análise robustos, métodos computacionais passaram a ser amplamente empregados para identificar padrões ocultos no mercado. O presente trabalho contextualiza-se na aplicação de inteligência artificial em séries temporais financeiras.

A motivação para este estudo provém da dificuldade de investidores e analistas em processar grandes volumes de dados de mercado para embasar decisões. Observa-se uma lacuna no acesso a ferramentas preditivas simplificadas e diretas que auxiliem na compreensão das tendências de ativos da Bolsa de Valores (B3).

Para solucionar esta questão, adotou-se a Opção Framework, empregando a biblioteca scikit-learn para solucionar um problema de predição de negócio. O objetivo geral deste projeto é desenvolver um modelo preditivo de Machine Learning capaz de prever a tendência direcional de fechamento (alta ou baixa) de ações listadas na B3.

Para atingir este propósito, definiram-se os seguintes objetivos específicos:

- Coletar e estruturar um dataset original de séries temporais financeiras;
- Realizar a análise exploratória e a preparação dos dados (EDA) utilizando Python;
- Treinar e avaliar algoritmos de classificação supervisionada.

A justificativa deste trabalho repousa na otimização da análise financeira. Modelagens automatizadas diminuem o tempo gasto em análises manuais e oferecem um suporte analítico

embasado em dados concretos. O documento está estruturado com um referencial teórico, seguido pela descrição do problema, discussão ética, detalhamento da metodologia aplicada na extração e preparação dos dados, e os resultados esperados para a conclusão do projeto.

## 2. Referencial Teórico

O desenvolvimento de soluções de Inteligência Artificial requer o entendimento de conceitos que transitam desde a teoria computacional clássica até a aplicação em negócios. A Inteligência Artificial (IA) moderna foca na construção de agentes racionais e modelos analíticos que buscam maximizar o sucesso em tarefas específicas através de aprendizado automático (RUSSELL; NORVIG, 2010).

Dentro desse espectro, o Aprendizado de Máquina (Machine Learning) destaca-se como a subárea responsável por conceder aos sistemas a capacidade de aprender a partir de dados, sem serem explicitamente programados para regras fixas. Na esfera dos negócios e de relatórios preditivos, o uso de algoritmos supervisionados — como Máquinas de Vetores de Suporte (SVM) e Florestas Aleatórias (Random Forest) — provou-se altamente eficaz na categorização e previsão de cenários, ferramentas estas amplamente disponibilizadas pelo ecossistema do scikit-learn (GÉRON, 2019).

A aplicação destas técnicas em finanças baseia-se na premissa de que o histórico de preços e volumes (séries temporais) carrega informações e padrões latentes sobre a ação dos investidores (AGGARWAL, 2021). A integração desses algoritmos forma um arcabouço sólido para o processamento de dados e a construção de dashboards preditivos, traduzindo números brutos em inteligência aplicável.

## 3. Metodologia

A presente pesquisa classifica-se como de natureza quantitativa e aplicada, pois utiliza dados numéricos históricos para a construção de um modelo computacional voltado à resolução de um problema prático no mercado financeiro. Para alcançar o objetivo proposto, adotou-se o método de Aprendizado de Máquina Supervisionado, enquadrando-se na "Opção Framework" da disciplina por meio da utilização da biblioteca scikit-learn.

Os dados utilizados consistem em séries temporais financeiras (histórico diário de cotações dos últimos dois anos) de cinco ativos de grande liquidez listados na B3: Petrobras (PETR4.SA), Vale (VALE3.SA), Itaú (ITUB4.SA), Bradesco (BBDC4.SA) e Ambev (ABEV3.SA). A coleta dos dados foi realizada de forma automatizada e ativa pelo grupo, por meio da extração via API pública do Yahoo Finance (biblioteca yfinance em Python), garantindo a originalidade do dataset. Como os dados extraídos referem-se estritamente a indicadores de mercado aberto (valores de ações e volumes financeiros), a pesquisa não envolve seres humanos, animais ou dados sensíveis, dispensando a submissão ao Comitê de Ética em Pesquisa, mas mantendo a responsabilidade algorítmica.

As técnicas de tratamento e análise, relacionadas aos objetivos específicos do projeto, foram divididas em duas etapas:

1. **Análise Exploratória de Dados (EDA) e Preparação:** Utilizando as bibliotecas pandas, matplotlib e seaborn, os dados brutos foram verificados quanto à existência de valores nulos, anomalias e escalas. A coluna de data foi padronizada e as variáveis de Abertura (Open), Fechamento (Close), Máxima (High), Mínima (Low) e Volume foram consolidadas.
2. **Engenharia de Recursos (Feature Engineering) e Modelagem:** Os resultados alcançados na predição serão analisados mediante a criação de uma variável categórica "Alvo" (Target), que indicará 1 para fechamentos em alta e 0 para fechamentos em baixa no dia subsequente. O dataset será particionado em bases de treino e teste. Modelos de classificação, como Regressão Logística e Random Forest, serão instanciados e avaliados com base em métricas de desempenho como Acurácia (Accuracy), Precisão (Precision) e Matriz de Confusão.

#### 4. Resultados e discussão

Nesta etapa inicial do projeto (N1), os resultados concentram-se na obtenção, estruturação e Análise Exploratória de Dados (EDA), fundamentais para a viabilidade do modelo preditivo. A extração via API resultou em um dataset íntegro e robusto, composto por 2.495 registros válidos, sem a presença de valores nulos ou dados corrompidos.

A Tabela 1 apresenta a estatística descritiva dos preços de fechamento para os cinco ativos analisados, evidenciando a escala e a volatilidade (através do desvio padrão e dos valores extremos) de cada papel nos últimos 24 meses.


**Tabela 1 - Estatística Descritiva dos Preços de Fechamento (Últimos 2 anos)**

| Ativo (Ticker) | Média de Preço (R\$) | Desvio Padrão | Mínimo (R\$) | Máximo (R\$) |
|----------------|----------------------|---------------|--------------|--------------|
| ABEV3.SA       | 13,18                | 1,91          | 10,04        | 16,90        |
| BBDC4.SA       | 15,21                | 3,17          | 9,80         | 20,87        |
| ITUB4.SA       | 34,36                | 6,70          | 22,71        | 48,38        |
| PETR4.SA       | 32,80                | 6,15          | 25,66        | 49,12        |
| VALE3.SA       | 60,83                | 13,82         | 43,93        | 87,63        |

Fonte: Elaborado pelos autores (2026).

Para melhor ilustrar o comportamento temporal e a variação descrita na tabela, a Figura 1 exibe a evolução histórica do preço de fechamento (Close) de cada ação da B3 que compõe a base de dados.

**Figura 1 - Evolução do Preço de Fechamento Histórico das Ações**



Fonte: Elaborado pelos autores via Python (2026).

Conforme observado na Tabela 1 e na Figura 1, os ativos apresentaram expressiva variação de máxima e mínima (volatilidade), ratificando a complexidade do problema de predição e justificando o uso de algoritmos avançados de Machine Learning para a próxima etapa.

Como ponto positivo da metodologia empregada até o momento, destaca-se a automação completa do pipeline de dados, desde a extração até a visualização analítica, o que mitiga erros manuais e permite que o modelo seja alimentado com dados atualizados no futuro. Como análise crítica, no entanto, é importante pontuar que a dependência exclusiva de variáveis numéricas históricas pode limitar a capacidade de predição do modelo diante de eventos externos e imprevisíveis do mercado financeiro. Os resultados da acurácia e precisão finais dos algoritmos de classificação serão apresentados e discutidos na etapa de desenvolvimento completo do projeto (N2).

## 5. Conclusão

Este trabalho propõe-se a enfrentar o problema da incerteza e da alta volatilidade no mercado de capitais por meio de técnicas de Inteligência Artificial. O objetivo geral de estruturar e preparar o desenvolvimento de um modelo preditivo para ações da B3 foi alcançado nesta

primeira fase, com sucesso na definição das ferramentas metodológicas, captura via Yahoo Finance e análise exploratória em Python.

Em suma, os resultados preliminares atestam a qualidade do dataset original formado por 2.495 instâncias financeiras, fornecendo a sustentação matemática e estrutural necessária para o treinamento de algoritmos via scikit-learn. A pesquisa confirma a viabilidade técnica de construir artefatos de dados acessíveis para otimizar o suporte à tomada de decisões em negócios, reduzindo a assimetria informacional de investidores.

Entre as principais contribuições deste projeto, ressalta-se a criação de um pipeline fim a fim, desde a extração até a visualização analítica de séries temporais. Contudo, o projeto reconhece limitações inerentes à área: o mercado financeiro é sensível a fatores exógenos (como decisões políticas e eventos globais) que não estão plenamente refletidos no histórico de preços.

Como trabalhos futuros inspirados por este escopo, sugere-se a expansão da metodologia para englobar a análise de sentimentos (Processamento de Linguagem Natural - NLP) de notícias do mercado financeiro, combinando variáveis numéricas e textuais para enriquecer o algoritmo, ou a aplicação de modelos de Aprendizado Profundo (Deep Learning), como redes neurais recorrentes (LSTMs), especializadas em sequências temporais de longo prazo.

## 6. Referências bibliográficas

AGGARWAL, C. C. **Artificial Intelligence: A Textbook**. New York: Springer, 2021.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 6023**: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. 2. ed. Sebastopol: O'Reilly, 2019.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3. ed. Upper Saddle River: Pearson, 2010.

UNIVERSIDADE PRESBITERIANA MACKENZIE. **Guia do TCC**: Orientações gerais para a elaboração do trabalho de conclusão dos cursos de graduação. São Paulo: UPM, 2021.

Link para o GitHub: <https://github.com/racabralm/IA-Projeto/tree/main>