

Predição de Tendências no Mercado Financeiro com Machine Learning

Rafael Araujo Cabral Moreira¹
Rute Willemann¹
Prof. Dr. Leandro Zerbinatti (Orientador)¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<rafaelaraujo.moreira, rute.willemann@mackenzista.com.br>
<leandro.zerbinatti@mackenzie.br>

2026

Resumo

O mercado financeiro caracteriza-se por sua alta volatilidade e pela complexidade na tomada de decisões. Este projeto insere-se no contexto de finanças quantitativas, motivado pela necessidade de reduzir a assimetria de informações e aprimorar a precisão preditiva de ativos. O objetivo geral é desenvolver um modelo preditivo de Machine Learning para prever a tendência de fechamento de ações da Bolsa de Valores brasileira (B3). A justificativa baseia-se na relevância de democratizar ferramentas de inteligência de negócios e suporte à decisão. A metodologia possui natureza quantitativa, adotando a "Opção Framework" estabelecida pela disciplina, com a utilização da biblioteca scikit-learn. O dataset original foi capturado via API oficial do Yahoo Finance, englobando dois anos de histórico das empresas Petrobras, Vale, Itaú, Bradesco e Ambev. A preparação e a análise exploratória dos dados foram conduzidas em Python, englobando limpeza e estatística descritiva. Como resultados esperados, almeja-se que o classificador seja capaz de indicar a direção (alta ou baixa) do ativo com assertividade superior à probabilidade aleatória, provendo um artefato técnico seguro e eticamente alinhado às boas práticas de Inteligência Artificial.

Palavras-chave: artigo científico; norma ABNT; inteligência artificial; machine learning; mercado financeiro; séries temporais.

Abstract

The financial market is characterized by high volatility and complex decision-making. This project falls within the context of quantitative finance, motivated by the need to

reduce information asymmetry and improve the predictive accuracy of assets. The general objective is to develop a Machine Learning predictive model to forecast the closing trend of stocks on the Brazilian Stock Exchange (B3). The justification relies on the relevance of democratizing business intelligence and decision-support tools. The methodology is quantitative, adopting the "Framework Option" established by the course, utilizing the scikit-learn library. The original dataset was captured via the official Yahoo Finance API, encompassing a two-year history of Petrobras, Vale, Itaú, Bradesco, and Ambev. Data preparation and exploratory analysis were conducted in Python, including data cleaning and descriptive statistics. As expected results, the classifier aims to indicate the asset's direction (up or down) with accuracy superior to random probability, providing a secure technical artifact that aligns with ethical Artificial Intelligence practices.

Keywords: Scientific article; ABNT standards; artificial intelligence; machine learning; financial market; time series.

1. Introdução

A capacidade de antecipar movimentos em mercados de capitais tem sido um dos maiores desafios empíricos e teóricos da área de negócios e finanças. Com a evolução da engenharia de dados e a popularização de pipelines de análise robustos, métodos computacionais passaram a ser amplamente empregados para identificar padrões ocultos no mercado. O presente trabalho contextualiza-se na aplicação de inteligência artificial em séries temporais financeiras.

A motivação para este estudo provém da dificuldade de investidores e analistas em processar grandes volumes de dados de mercado para embasar decisões. Observa-se uma lacuna no acesso a ferramentas preditivas simplificadas e diretas que auxiliem na compreensão das tendências de ativos da Bolsa de Valores (B3).

Para solucionar esta questão, adotou-se a Opção Framework, empregando a biblioteca scikit-learn para solucionar um problema de predição de negócio. O objetivo geral deste projeto é desenvolver um modelo preditivo de Machine Learning capaz de prever a tendência direcional de fechamento (alta ou baixa) de ações listadas na B3.

Para atingir este propósito, definiram-se os seguintes objetivos específicos:

- Coletar e estruturar um dataset original de séries temporais financeiras;
- Realizar a análise exploratória e a preparação dos dados (EDA) utilizando Python;
- Treinar e avaliar algoritmos de classificação supervisionada.

A justificativa deste trabalho repousa na otimização da análise financeira. Modelagens automatizadas diminuem o tempo gasto em análises manuais e oferecem um suporte analítico embasado em dados concretos. O documento está estruturado com um referencial teórico, seguido pela descrição do problema, discussão ética, detalhamento da metodologia aplicada na extração e preparação dos dados, e os resultados esperados para a conclusão do projeto.

2. Referencial Teórico

O desenvolvimento de soluções de Inteligência Artificial requer o entendimento de conceitos que transitam desde a teoria computacional clássica até a aplicação em negócios. A Inteligência Artificial (IA) moderna foca na construção de agentes racionais e modelos analíticos

que buscam maximizar o sucesso em tarefas específicas através de aprendizado automático (RUSSELL; NORVIG, 2010).

Dentro desse espectro, o Aprendizado de Máquina (Machine Learning) destaca-se como a subárea responsável por conceder aos sistemas a capacidade de aprender a partir de dados, sem serem explicitamente programados para regras fixas. Na esfera dos negócios e de relatórios preditivos, o uso de algoritmos supervisionados — como Máquinas de Vetores de Suporte (SVM) e Florestas Aleatórias (Random Forest) — provou-se altamente eficaz na categorização e predição de cenários, ferramentas estas amplamente disponibilizadas pelo ecossistema do scikit-learn (GÉRON, 2019).

A aplicação destas técnicas em finanças baseia-se na premissa de que o histórico de preços e volumes (séries temporais) carrega informações e padrões latentes sobre a ação dos investidores (AGGARWAL, 2021). A integração desses algoritmos forma um arcabouço sólido para o processamento de dados e a construção de dashboards preditivos, traduzindo números brutos em inteligência aplicável.

3. Metodologia

A presente pesquisa classifica-se como de natureza quantitativa e aplicada, pois utiliza dados numéricos históricos para a construção de um modelo computacional voltado à resolução de um problema prático no mercado financeiro. Para alcançar o objetivo proposto, adotou-se o método de Aprendizado de Máquina Supervisionado, enquadrando-se na "Opção Framework" da disciplina por meio da utilização da biblioteca scikit-learn.

Os dados utilizados consistem em séries temporais financeiras (histórico diário de cotações dos últimos dois anos) de cinco ativos de grande liquidez listados na B3: Petrobras (PETR4.SA), Vale (VALE3.SA), Itaú (ITUB4.SA), Bradesco (BBDC4.SA) e Ambev (ABEV3.SA). A coleta dos dados foi realizada de forma automatizada e ativa pelo grupo, por meio da extração via API pública do Yahoo Finance (biblioteca yfinance em Python), garantindo a originalidade do dataset. Como os dados extraídos referem-se estritamente a indicadores de mercado aberto (valores de ações e volumes financeiros), a pesquisa não envolve seres humanos, animais ou dados sensíveis, dispensando a submissão ao Comitê de Ética em Pesquisa, mas mantendo a responsabilidade algorítmica.

As técnicas de tratamento e análise, relacionadas aos objetivos específicos do projeto, foram divididas em duas etapas:

1. **Análise Exploratória de Dados (EDA) e Preparação:** Utilizando as bibliotecas pandas, matplotlib e seaborn, os dados brutos foram verificados quanto à existência de valores nulos, anomalias e escalas. A coluna de data foi padronizada e as variáveis de Abertura (Open), Fechamento (Close), Máxima (High), Mínima (Low) e Volume foram consolidadas.
2. **Engenharia de Recursos (Feature Engineering) e Modelagem:** Os resultados alcançados na predição serão analisados mediante a criação de uma variável categórica "Alvo" (Target), que indicará 1 para fechamentos em alta e 0 para fechamentos em baixa no dia subsequente. O dataset será particionado em bases de treino e teste. Modelos de classificação, como Regressão Logística e Random Forest, serão instanciados e avaliados

com base em métricas de desempenho como Acurácia (Accuracy), Precisão (Precision) e Matriz de Confusão.

4. Resultados e discussão

Nesta etapa inicial do projeto (N1), os resultados concentram-se na obtenção, estruturação e Análise Exploratória de Dados (EDA), fundamentais para a viabilidade do modelo preditivo. A extração via API resultou em um dataset íntegro e robusto, composto por 2.495 registros válidos, sem a presença de valores nulos ou dados corrompidos.

A Tabela 1 apresenta a estatística descritiva dos preços de fechamento para os cinco ativos analisados, evidenciando a escala e a volatilidade (através do desvio padrão e dos valores extremos) de cada papel nos últimos 24 meses.


Tabela 1 - Estatística Descritiva dos Preços de Fechamento (Últimos 2 anos)

Ativo (Ticker)	Média de Preço (R\$)	Desvio Padrão	Mínimo (R\$)	Máximo (R\$)
ABEV3.SA	13,18	1,91	10,04	16,90
BBDC4.SA	15,21	3,17	9,80	20,87
ITUB4.SA	34,36	6,70	22,71	48,38
PETR4.SA	32,80	6,15	25,66	49,12
VALE3.SA	60,83	13,82	43,93	87,63

Fonte: Elaborado pelos autores (2026).

Para melhor ilustrar o comportamento temporal e a variação descrita na tabela, a Figura 1 exibe a evolução histórica do preço de fechamento (Close) de cada ação da B3 que compõe a base de dados.

Figura 1 - Evolução do Preço de Fechamento Histórico das Ações



Fonte: Elaborado pelos autores via Python (2026).

Conforme observado na Tabela 1 e na Figura 1, os ativos apresentaram expressiva variação de máxima e mínima (volatilidade), ratificando a complexidade do problema de predição e justificando o uso de algoritmos avançados de Machine Learning para a próxima etapa.

Como ponto positivo da metodologia empregada até o momento, destaca-se a automação completa do pipeline de dados, desde a extração até a visualização analítica, o que mitiga erros manuais e permite que o modelo seja alimentado com dados atualizados no futuro. Como análise crítica, no entanto, é importante pontuar que a dependência exclusiva de variáveis numéricas históricas pode limitar a capacidade de predição do modelo diante de eventos externos e imprevisíveis do mercado financeiro. Os resultados da acurácia e precisão finais dos algoritmos de classificação serão apresentados e discutidos na etapa de desenvolvimento completo do projeto (N2).

5. Conclusão

Este trabalho propõe-se a enfrentar o problema da incerteza e da alta volatilidade no mercado de capitais por meio de técnicas de Inteligência Artificial. O objetivo geral de estruturar e preparar o desenvolvimento de um modelo preditivo para ações da B3 foi alcançado nesta primeira fase, com sucesso na definição das ferramentas metodológicas, captura via Yahoo Finance e análise exploratória em Python.

Em suma, os resultados preliminares atestam a qualidade do dataset original formado por 2.495 instâncias financeiras, fornecendo a sustentação matemática e estrutural necessária para o treinamento de algoritmos via scikit-learn. A pesquisa confirma a viabilidade técnica de construir artefatos de dados acessíveis para otimizar o suporte à tomada de decisões em negócios, reduzindo a assimetria informacional de investidores.

Entre as principais contribuições deste projeto, ressalta-se a criação de um pipeline fim a fim, desde a extração até a visualização analítica de séries temporais. Contudo, o projeto reconhece limitações inerentes à área: o mercado financeiro é sensível a fatores exógenos (como decisões políticas e eventos globais) que não estão plenamente refletidos no histórico de preços.

Como trabalhos futuros inspirados por este escopo, sugere-se a expansão da metodologia para englobar a análise de sentimentos (Processamento de Linguagem Natural - NLP) de notícias do mercado financeiro, combinando variáveis numéricas e textuais para enriquecer o algoritmo, ou a aplicação de modelos de Aprendizado Profundo (Deep Learning), como redes neurais recorrentes (LSTMs), especializadas em sequências temporais de longo prazo.

6. Referências bibliográficas

AGGARWAL, C. C. Artificial Intelligence: A Textbook. New York: Springer, 2021.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

GÉRON, A. Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol: O'Reilly, 2019.

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 3. ed. Upper Saddle River: Pearson, 2010.

UNIVERSIDADE PRESBITERIANA MACKENZIE. Guia do TCC: Orientações gerais para a elaboração do trabalho de conclusão dos cursos de graduação. São Paulo: UPM, 2021.